

卒業論文

深層ニューラルネットワークを用いた
Kosterlitz-Thouless 転移の相構造の学習

早稲田大学 先進理工学部 物理学科
学籍番号 1Y22A006-1

伊藤 颯汰郎

2026 年 1 月 25 日

Contents

1	序論	2
2	Kosterlitz–Thouless 転移の理論的背景	2
2.1	二次元 XY モデルと連続対称性	2
2.2	長距離秩序の不在と KT 相の性質	2
2.3	渦の構造とトポロジー	3
2.4	ヘリシティ剛性と準長距離秩序	3
2.5	渦対の解離としての Kosterlitz–Thouless 転移	3
3	数値計算・機械学習手法	4
3.1	モンテカルロシミュレーション	4
3.2	観測量の定義と計算法	5
3.3	教師あり学習による基準モデル	6
3.4	教師なし学習による相構造解析の枠組み (先行研究)	7
3.5	本研究の教師なし・自己教師モデル (提案手法)	9
3.6	潜在変数の解析	11
4	結果	13
4.1	教師あり学習	13
4.2	教師なし学習 (contrastive + 自己教師) による相構造解析	16
4.3	クラスタ条件付き相関関数による空間構造の解析	22
5	まとめ	23
5.1	考察	23
5.2	結論と今後の展望	24

1 序論

二次元 XY モデルは、連続対称性を持つスピン系の代表的なモデルであり、低温相 (KT 相) と高温相の間に自発的対称性の破れを伴わない Kosterlitz–Thouless (KT) 転移 [1] を示すことが知られている。この転移は、渦・反渦対の束縛と解離というトポロジカル欠陥の振る舞いによって特徴づけられ、統計物理学において重要な位置を占めている。

一方で、KT 転移は局所的な秩序変数を持たないため、有限サイズ系や数値シミュレーションにおいて転移点の同定が困難であるという問題がある。近年、機械学習、特に教師無し機械学習を用いて物理系の相構造を解析する試みが盛んに行われているが、学習された潜在変数がどのような物理量と対応しているかについては十分に理解されていない。

本研究では、二次元 XY モデルに対して数値シミュレーションと機械学習を組み合わせ、KT 転移近傍における潜在変数の振る舞いを解析することを目的とする。特に、温度変化に伴う潜在変数の応答と、渦密度やヘリシティ剛性といった物理量との対応関係に注目する。

2 Kosterlitz–Thouless 転移の理論的背景

2.1 二次元 XY モデルと連続対称性

二次元 XY モデルは、各格子点において角度変数 $\phi_i \in [0, 2\pi)$ をもつスピンが定義された古典スピンモデルである。スピンは平面内で自由に回転することができ、隣接するスピン同士ができるだけ同じ向きを向くように相互作用する。このモデルのハミルトニアンは次式で与えられる：

$$H = -J \sum_{\langle i,j \rangle} \cos(\phi_i - \phi_j), \quad (1)$$

ここで $J > 0$ は強磁性的相互作用定数であり、 $\langle i,j \rangle$ は最近接格子点の組を表す。

XY モデルの重要な特徴は、スピンの角度を一様に回転させる変換 $\phi_i \rightarrow \phi_i + \theta$ (θ は任意の定数) に対してハミルトニアンが不変である点にある。この性質は連続な回転対称性 ($U(1)$ 対称性) と呼ばれ、イジング模型のような離散対称性をもつモデルとは本質的に異なる。

一般に、対称性をもつ多体系では低温で対称性が自発的に破れることにより秩序相が実現することが多い。しかし、二次元系においては連続対称性をもつ場合に有限温度で長距離秩序が形成されないことが Mermin–Wagner の定理によって示されている。したがって、二次元 XY モデルでは、有限温度において自発磁化をもつ通常の秩序相は存在しない。

それにもかかわらず、二次元 XY モデルは低温領域において相関関数がべき的に減衰する特異な相を示す。この相は真の長距離秩序を持たないものの、通常の高温度とは異なる性質を持つため、準長距離秩序をもつ相と呼ばれる。

2.2 長距離秩序の不在と KT 相の性質

前節で述べたように、二次元 XY モデルは連続対称性をもつため、Mermin–Wagner の定理 [2] により有限温度において自発磁化を伴う長距離秩序は存在しない。すなわち、スピンの向きが系全体にわたって一様に揃うような秩序相は実現しない。

しかしながら、低温領域においては、スピン間の相関が完全に失われるわけではない。二点相関関数

$$G(r) = \langle \cos(\phi(\mathbf{r}) - \phi(\mathbf{0})) \rangle \quad (2)$$

は、KT 相において距離 r に対して指数関数的には減衰せず、べき関数的な減衰

$$G(r) \sim r^{-\eta(T)} \quad (3)$$

を示す。ここで $\eta(T)$ は温度に依存する臨界指数である。

このように、相関関数がべき的に減衰する相は真の長距離秩序を持たないものの、高温相とは明確に異なる性質を示す。そのためにこの KT 相は準長距離秩序 (quasi long-range order) を持つ相と呼ばれるのである。二次元 XY モデルにおける相転移は、この準長距離秩序相と相関が指数関数的に減衰する高温相との間で生じる。

2.3 渦の構造とトポロジー

二次元 XY モデルにおける KT 相の性質を理解するうえで、スピン配置に現れるトポロジカル欠陥である渦の存在が重要である。連続な角度場 $\phi(\mathbf{r})$ に対して、閉曲線 C に沿った角度の変化を考えると、

$$\oint_C \nabla \phi \cdot d\mathbf{r} = 2\pi n \quad (4)$$

が成り立つ場合がある。ここで n は整数であり、渦の巻き数を表す。

$n = +1$ の場合には正の渦、 $n = -1$ の場合には反渦と呼ばれる。渦の中心では角度場 ϕ が連続的に定義できず、スピン配置は特異点を持つ。このような渦は局所的な摂動では消去できず、トポロジカルに安定な欠陥として振る舞う。

単独の渦を生成するためには、角度場の勾配が広い範囲にわたって大きくなるため、エネルギーは系サイズに対して対数的に発散する。一方で、正の渦と反渦が近接して対を形成した場合には、それぞれの角度変化が互いに打ち消し合い、エネルギーコストは有限となる。そのため、低温領域では渦・反渦対が束縛された状態で存在する。

温度が上昇すると、自由エネルギーにおけるエントロピー項の寄与が大きくなり渦・反渦対が解離し、自由な渦が系中に増殖する。この渦の解離が起こる温度が Kosterlitz–Thouless 転移温度 T_{KT} であり、準長距離秩序相から高温相への転移が生じる。

2.4 ヘリシティ剛性と準長距離秩序

二次元 XY モデルにおける KT 相の性質を特徴づける重要な物理量として、ヘリシティ剛性 (helicity modulus, あるいはスピン剛性) が挙げられる。ヘリシティ剛性とは、スピン角度に空間的なねじれ (位相勾配) を与えたときの自由エネルギーの応答を表す量であり、系が一様なスピン配列をどの程度保とうとするかを測る指標である。

具体的には、 x 方向に一様な位相ねじれ θ を与えたときの自由エネルギー $F(\theta)$ を用いて、ヘリシティ剛性 Υ は

$$\Upsilon = \frac{1}{N} \left. \frac{\partial^2 F(\theta)}{\partial \theta^2} \right|_{\theta=0} \quad (5)$$

として定義される。ここで N は系の全スピン数である。 Υ が有限であることは、長波長の位相変動に対して系が剛性的に応答することを意味する。

二次元 XY モデルの KT 相では、真の長距離秩序は存在しないものの、長距離スケールにわたって位相の揺らぎが抑制されており、ヘリシティ剛性は有限の値をとる。この剛性の存在が、相関関数が指数関数的ではなくべき関数的に減衰する準長距離秩序相の基盤となっている。

実際、スピン波近似のもとでは、二点相関関数の臨界指数 $\eta(T)$ とヘリシティ剛性 Υ の間に

$$\eta(T) = \frac{T}{2\pi\Upsilon} \quad (6)$$

という関係が成り立つ。この式は、KT 相における相関関数のべき的減衰が、有限なヘリシティ剛性に支えられていることを示している。

また、温度が上昇すると、渦・反渦対の解離が進行し、長距離スケールで位相の乱れが増大する。その結果ヘリシティ剛性は減少し、Kosterlitz–Thouless 転移点において普遍的な値をもって不連続に消失する。すなわち Υ は

$$\Upsilon(T_{KT}^-) = \frac{2T_{KT}}{\pi} \quad (7)$$

という普遍的な値をとった後、不連続にゼロへと消失する。このヘリシティジャンプは、KT 転移を特徴づける最も重要な性質の一つである。

2.5 渦対の解離としての Kosterlitz–Thouless 転移

これまでに述べたように、二次元 XY モデルの KT 相では、トポロジカル欠陥である正の渦と反渦が対を形成し、束縛された状態で存在している。このとき、長距離スケールにおける位相の

乱れは抑制されており、ヘリシティ剛性は有限の値を保つ。その結果、相関関数は指数関数的ではなくべき関数的に減衰し、準長距離秩序相が実現する。

温度が上昇すると、渦・反渦対の束縛に伴うエネルギー利得よりも、渦が自由に存在できることによるエントロピー利得が次第に支配的となる。この自由エネルギーの競合により、ある臨界温度において渦・反渦対は解離し、自由な渦が系中に増殖する。この渦の解離が生じる温度が、Kosterlitz–Thouless 転移温度 T_{KT} である。

渦が自由化すると、長距離にわたる位相の剛性は失われ、ヘリシティ剛性は T_{KT} において不連続に消失する。これに伴い、KT 相で見られた準長距離秩序は崩壊し、高温相では相関関数は有限な相関長をもつ指数関数的減衰を示す。

このように、Kosterlitz–Thouless 転移は、自発磁化や局所的な秩序変数の非零化によって特徴づけられる通常の相転移とは本質的に異なる。代わりに、トポロジカル欠陥である渦の束縛・解離という非局所的な機構によって引き起こされる点に特徴があり、トポロジカル相転移の代表例として位置づけられている。

以上の議論から、二次元 XY モデルにおける相転移の理解には、スピン配置の局所的な性質だけでなく、渦の分布やヘリシティ剛性といった大域的・トポロジカルな量の振る舞いを併せて解析することが不可欠である。本研究では、この観点に基づき、数値シミュレーションおよび機械学習を用いて、KT 転移近傍における渦構造および機械学習により得られた特徴空間の構造と潜在変数の挙動を調べる。

3 数値計算・機械学習手法

3.1 モンテカルロシミュレーション

本研究では、二次元 XY モデルの平衡状態をサンプリングするために、モンテカルロ法による数値シミュレーションを行った。基本更新として単一スピン更新の Metropolis 法 [3] を用い、必要に応じてオーバーリラクゼーション更新 [4] を併用した [5]。以下では本研究で用いた更新則、熱化・測定手順、および温度走査の方法をまとめる。

3.1.1 Metropolis 更新 (単一スピン更新)

格子サイズを $L \times L$ とし、各格子点 i の角度変数を $\phi_i \in (-\pi, \pi]$ とする。Metropolis 更新では、1 スweepあたり L^2 回の単一サイト更新を行う。具体的には、サイトをランダム順序で走査し、各サイトで

$$\phi_i \rightarrow \phi'_i = \text{wrap}(\phi_i + \delta), \quad \delta \sim U(-\Delta_\phi, \Delta_\phi) \quad (8)$$

という局所提案を行う。ここで $\text{wrap}(\cdot)$ は角度を $(-\pi, \pi]$ に折り畳む演算である。提案に対するエネルギー差 ΔE を近接結合のみから局所的に計算し、

$$P_{\text{acc}} = \min\left(1, e^{-\beta \Delta E}\right), \quad \beta = \frac{1}{T} \quad (9)$$

に従って受理・棄却を行う。本研究の実装では、各スweepでサイト順序を乱数でシャッフルして更新している。

3.1.2 オーバーリラクゼーション更新

臨界近傍では自己相関が大きくなりやすいため、Metropolis 更新に加えてオーバーリラクゼーション更新を併用した。これは、各サイトの局所場 (近傍スピンのベクトル和) に関してスピンを鏡映する更新であり、エネルギーを保存したまま位相を変化させることでサンプリング効率を改善する。本研究では1 スweepごとに Metropolis 更新の後、必要に応じてオーバーリラクゼーション更新を1回適用した。

3.1.3 提案幅の自動調整

Metropolis 法の効率は提案幅 Δ_ϕ に依存するため、受理率が適度な範囲に入るよう Δ_ϕ を温度ごとに緩やかに調整した。[6] 具体的には、各スイープで得られる受理率に応じて Δ_ϕ を増減させ、受理率が概ね 0.4 ~ 0.6 に収まるよう制御した。なお、測定過程では調整後の Δ_ϕ を固定して用いた。

3.1.4 熱化・測定手順と温度走査

各温度 T について、まず熱化 (バーンイン) として N_{therm} スイープ実行し、その後に測定として N_{meas} スイープ実行した。測定フェーズでは、 n_{int} スイープごとに観測量を記録した。また、温度走査では前の温度で得られた最終スピン配置を次の温度の初期状態として引き継ぐことで、温度ごとの立ち上がりを安定化させた。

3.1.5 シミュレーション条件

本研究で用いた代表的なシミュレーション条件を以下に示す。格子サイズ L 、温度点 $\{T\}$ 、熱化・測定スイープ数などは設定ファイルで管理した。

- 格子サイズ: $L = 32$
- 相互作用定数: $J = 1.0$
- 温度走査: 低温域から高温域までを広く覆うため、 $T = 0.3$ から 1.5 の範囲で温度を設定した。特に KT 転移近傍では温度依存性を詳細に解析するため、 $T = 0.80$ から 1.00 の範囲では温度刻みを細かく取り、それ以外の領域では比較的粗い刻みで温度点を選択した。
- 熱化スイープ数: $N_{\text{therm}} = 5000$
- 測定スイープ数: $N_{\text{meas}} = 20000$
- サンプルング間隔: $n_{\text{int}} = 20$ (n_{int} スイープごとに測定)
- Metropolis 提案幅初期値: $\Delta_\phi = \pi/3$ (受理率により自動調整)
- 併用更新: オーバーリラクゼーション更新

測定ではエネルギー密度、ヘリシティ剛性、渦密度、および相関関数を記録し、温度依存性を解析した。これら観測量の定義と計算法は次節で述べる。

3.2 観測量の定義と計算法

本研究では、二次元 XY モデルにおける相構造および KT 転移の性質を調べるため、モンテカルロシミュレーションから得られたスピン配置に対して、いくつかの物理量を測定した。本節では、エネルギー、ヘリシティ剛性、渦密度、および相関関数の定義と、それらの計算法をまとめる。

3.2.1 エネルギーおよびエネルギー密度

系のエネルギーは、XY モデルのハミルトニアン

$$H = -J \sum_{\langle i,j \rangle} \cos(\phi_i - \phi_j) \quad (10)$$

によって定義される。シミュレーションでは、各スイープ後のスピン配置に対して全エネルギー H を計算し、格子点数 $N = L^2$ で割ることでエネルギー密度

$$e = \frac{H}{N} \quad (11)$$

を求めた。エネルギー密度は、温度に対する系の平均的な振る舞いを把握するための基本的な指標として用いた。

3.2.2 ヘリシティ剛性

KT 転移において重要な物理量の一つが、ヘリシティ剛性 (helicity modulus) である。ヘリシティ剛性は、境界条件にねじれを与えたときの自由エネルギーの応答を表し、KT 相では有限値を持つ一方、高温相ではゼロに近づく。

x 方向のヘリシティ剛性 Υ は、次式で定義される。：

$$\Upsilon = \frac{1}{N} \left\langle \sum_{\langle i,j \rangle_x} \cos(\phi_i - \phi_j) \right\rangle - \frac{\beta}{N} \left\langle \left(\sum_{\langle i,j \rangle_x} \sin(\phi_i - \phi_j) \right)^2 \right\rangle \quad (12)$$

ここで $\langle i,j \rangle_x$ は x 方向の最近接結合を表す。期待値は MC 平均で評価した。

3.2.3 渦密度

KT 転移の本質は、トポロジカル欠陥である渦の束縛と解離にある。そのため、本研究では渦密度を重要な観測量として測定した。

各プラケットについて、周囲の角度差を反時計回りに足し合わせ、

$$\sum_{\square} \Delta\phi = 2\pi n \quad (13)$$

となる整数 n を渦の巻き数として定義する。ここで角度差 $\Delta\phi$ は $(-\pi, \pi]$ の範囲に正規化したものを用いる。 $|n| = 1$ のプラケットを渦または反渦として数え、系全体における渦および反渦の総数を格子点数で割ることで渦密度を定義した。

渦密度は、KT 相では小さく抑えられ、KT 転移を超えると急激に増加するため、転移の進行を可視化する指標として用いた。

3.2.4 スピン相関関数

KT 相における準長距離秩序の性質を調べるため、二点相関関数を測定した。距離 r だけ離れた二点における相関関数は

$$G(r) = \langle \cos(\phi(\mathbf{r}) - \phi(\mathbf{0})) \rangle \quad (14)$$

で定義される。相関関数は、KT 相ではべき関数的に減衰し、高温相では指数関数的に減衰する。本研究では、温度変化に伴う $G(r)$ の挙動を比較することで、相構造の違いを確認した。

3.3 教師あり学習による基準モデル

本研究では、後述する教師無し学習および潜在変数空間の解析の基準として、二次元 XY モデルのスピン配置に対する、教師あり学習による温度領域分類モデルを構築した。本節で構築する教師あり分類モデルは、相の厳密な判定を目的とするものではなく、後述する教師無し学習において得られる特徴空間の構造および潜在変数の挙動を解釈するための参照的な基準として位置づけられる。すなわち、機械学習モデルが温度変化に伴うスピン配置の統計的特徴をどの程度捉えているかを評価するための、比較対象として導入されている。本節では、そのモデル構成、学習方法、および評価指標について述べる。

入力データとラベル

入力データには、モンテカルロシミュレーションによって生成した二次元 XY モデルのスピン角度配置を用いた。各格子点におけるスピン角 ϕ_i は、数値安定性および周期性を考慮し、 $\cos \phi_i$ および $\sin \phi_i$ の 2 チャンネルとした。したがって、入力はサイズ $(2, L, L)$ のテンソルである。

教師ラベルとしては、温度 T に基づいて定義した位相ラベルを用いた。KT 相、中間領域 (KT 転移近傍)、高温相の 3 つの領域に分類し、それぞれを異なるクラスとして扱う。KT 相および高温相に加えて、Kosterlitz–Thouless 転移近傍に対応する中間領域を独立したクラスとして定義理

由は KT 転移が通常の相転移とは異なり、局所的な秩序変数の非連続的变化によって明確に区別される相境界を持たないためである。特に有限サイズ系においては、転移近傍では準長距離秩序相と高温相の特徴が混在するため、この領域を一つのクラスとして扱うことは、学習の安定性および後述する解析との比較において有効であると考えられる。

なお、ここで設定した教師ラベルは、有限サイズ系における温度に基づいて定義されたものであり、熱力学極限における相の厳密な区分を意味するものではない。特に KT 転移近傍では、有限サイズ効果により相関関数やヘリシティ剛性の振る舞いが系サイズに依存して滑らかに変化するため、ラベルの境界は必然的に曖昧さを含む。したがって、本研究ではこれらのラベルをあくまで解析上の便宜的な指標として用い、教師無し学習によって得られる特徴空間の構造や潜在変数の挙動との対応関係を重視する。

モデル構成

基準分類モデルには、畳み込みニューラルネットワーク (CNN) を用いた。モデルは、複数層の畳み込み層とプーリング層からなるエンコーダ部と、全結合層からなる分類ヘッドで構成されている。エンコーダ部はスピン配置の空間的構造を抽出し、その出力を一次元の潜在特徴ベクトルへと変換する。

最終的に、全結合層を通じてクラス数と同じ次元の出力を得、softmax 関数を適用することで、各温度領域に対応する分類スコアを計算する。これらの出力は、各クラスに属する度合いを表す相対的な指標として解釈される。本研究では、このエンコーダの出力を後の解析において特徴空間上の潜在変数として用いる。

学習方法

学習は教師あり分類問題として行い、損失関数にはクロスエントロピー損失を用いた。最適化には Adam 法を用い、ミニバッチ学習によってネットワークの重みを更新した。学習データは訓練・検証・テスト用に分割し、検証データに対する性能をもとに過学習の抑制を行った。

評価指標

学習済みモデルの性能評価には、全体の分類精度に加え、温度ごとの正答率および softmax 出力のエントロピーを用いた。特に、KT 転移近傍では位相の判別が困難になるため、エントロピーの温度依存性は転移点付近における不確実性の指標として有用である。

本研究では、教師あり学習によって得られた潜在変数を基準として、次節以降で導入する教師無し学習による潜在構造との比較を行う。

3.4 教師なし学習による相構造解析の枠組み (先行研究)

本節では、教師ラベル (相ラベル) を与えずにスピン配置から学習し、相構造や転移点を同定する既存研究の枠組みを整理する。本研究の教師なし学習は、(i) スピン配置の学習 (潜在変数の獲得)、(ii) 潜在変数空間の構造解析 (クラスターや温度依存性)、(iii) 潜在変数と物理量の対応付けという 3 点を重視する。

3.4.1 教師なし学習による相構造の抽出

教師なし学習の代表的アプローチは、スピン配置 x を入力として低次元の潜在変数 z を獲得し、その分布構造や再構成誤差から相の違いを捉えるものである。代表例として、PCA やオートエンコーダ (AE)、変分オートエンコーダ (VAE) を用い、潜在変数が秩序変数に対応すること、および再構成誤差が転移点近傍で変化することが報告されている [7], [8]。

まず通常の AE では、エンコーダ f_θ とデコーダ g_ϕ を用いて

$$z = f_\theta(x), \quad \hat{x} = g_\phi(z)$$

とし、再構成損失

$$\mathcal{L}_{\text{AE}}(\theta, \phi) = \mathbb{E}_{x \sim \mathcal{D}} [\|x - \hat{x}\|^2] \quad (\text{あるいは画素/成分ごとのクロスエントロピー})$$

を最小化する．学習後，潜在変数 z を 1 次元または 2 次元にとると，各温度で得られたスピン配置が潜在変数空間でクラスタを形成し，その分離が相の違いと対応する，という見方が可能になる [8]．

VAE では潜在変数に分布を仮定し，事後分布を $q_\theta(z|x)$ ，事前分布を $p(z)$ として，以下の ELBO (Evidence Lower Bound) を最大化（符号を反転して最小化）する：

$$\mathcal{L}_{\text{VAE}}(\theta, \phi) = \mathbb{E}_{x \sim \mathcal{D}} [\mathbb{E}_{z \sim q_\theta(z|x)} [-\log p_\phi(x|z)] + \text{KL}(q_\theta(z|x) \| p(z))].$$

このとき，第 1 項は再構成誤差（負の対数尤度），第 2 項は潜在分布を正則化する項である．この枠組みでは，再構成誤差

$$\epsilon(x) = \|x - \hat{x}\| \quad \text{または} \quad -\log p_\phi(x|z)$$

を温度ごとに平均した $\langle \epsilon \rangle_T$ が転移点近傍で顕著に変化し，秩序変数を知らない場合でも転移検出の指標となりうることが示されている [7]．ここで $\|\cdot\|_2$ はユークリッドノルムを表し， $r = \|z\|_2$ は潜在変数空間における原点からの距離として定義される．

3.4.2 潜在変数と物理量の対応付け

教師なし学習の成果を物理に接続するためには，「潜在変数 z のどの成分が，どの物理量 Y と対応しているか」を検証する必要がある．先行研究では，次のような対応付けの枠組みが代表的に用いられている：

(a) 相関に基づく対応付け

温度 T でサンプルした配置 x から潜在変数 $z(x)$ を得て，既知の物理量 $Y(x)$ （例：磁化）との相関を調べる．

$$\rho_k = \text{Corr}(z_k(x), Y(x))$$

のように，各潜在成分 z_k の相関係数を計算し， $|\rho_k|$ が大きい成分を「物理量に対応する候補」とみなす．この操作により，秩序変数が明確な系では潜在変数が秩序変数と強く相関することが報告されている [7]．

(b) 回帰（線形/非線形）に基づく対応付け

潜在変数 $z(x)$ から物理量を推定する回帰モデル

$$\hat{Y}(x) = h_\psi(z(x))$$

を学習し，推定誤差や重要度から対応関係を評価する．最も単純には線形回帰

$$\hat{Y} = w^\top z + b$$

を用いる．このとき，係数 w_k の大きさは「どの潜在成分が Y に効いているか」を定量的に与える．

(c) 潜在変数空間の幾何に基づく対応付け

連続対称性や位相の自由度を持つ系では，単一成分ではなく「ノルム」「角度」「クラスタ半径」など潜在変数空間の幾何量が物理量に対応する可能性がある．例えば前節の

$$r = \|z\|_2$$

や，次元削減（t-SNE 等）による可視化により，温度で色分けした点群が連続的に変形するか／離散的に分離するかを評価する，といった解析が行われる [8]．

以上は本研究で行う「潜在変数と渦密度・ヘリシティ剛性等の対応付け」に直結する枠組みである．特に KT 転移では局所秩序変数が存在しないため，(a)(b) に加え，(c) のような潜在変数空間の幾何的構造を手掛かりにすることが重要となる．

本研究では、潜在変数空間の幾何に基づく解析として、対照学習 (contrastive learning) [9] によって得られる特徴空間の構造に着目する。

対照学習では、同一配置に由来する異なる拡張同士を近接させ、異なる配置由来の特徴を分離するように特徴空間が学習される。この過程により、特徴空間にはスピン配置の統計的・幾何的差異が反映されると期待される。

さらに、特徴空間上の点群構造に対して、クラスタ形成や連続的な変形の有無を解析し、それらが渦密度やヘリシティ剛性といった物理量の振る舞いとどのように対応するかを検討する。このような潜在変数空間の幾何的解析により、局所的な秩序変数が存在しない KT 転移に対して、対照学習によって抽出された特徴が相構造をどの程度反映しているかを明らかにする。

3.4.3 自己教師学習による転移点同定 (予測破綻・揺らぎ)

教師なし (unsupervised) の立場に近いが、「系の制御パラメータ (温度 T など) を予測させる」ことで相転移を同定する自己教師学習 (self-supervised learning) も提案されている。重要な点は、スピン配置 x と温度 T の間に一対一対応はなく、同じ配置が異なる温度で出現しうるため、単一サンプルに対して T を厳密に回帰すること自体には限界がある、という統計力学的背景がある [10]。この問題に対し、出力をアンサンブル平均して扱う枠組みが提案されている [11]。

具体的には、ニューラルネット F_θ により

$$\hat{\lambda} = F_\theta(x)$$

(λ は温度などの制御パラメータ) を出力させる。温度 (または λ) ごとに多数の独立サンプル $x^{(n)} \sim P_\lambda(x)$ を用意し、

$$\mu(\lambda) = \frac{1}{N_s} \sum_{n=1}^{N_s} F_\theta(x^{(n)}), \quad \sigma^2(\lambda) = \frac{1}{N_s} \sum_{n=1}^{N_s} \left(F_\theta(x^{(n)}) - \mu(\lambda) \right)^2$$

を定義する。相転移点は、 $\sigma(\lambda)$ の急増やその微分 $\frac{d\sigma}{d\lambda}$ のピークなど、揺らぎの異常として検出される。

本研究の立場は、自己教師的なモデル構造を取り入れつつも、予測精度そのものではなく学習された潜在変数の挙動に焦点を当てる。すなわち、潜在変数 z から物理量へ接続する回帰・相関解析を組み合わせ、さらに潜在変数空間の構造解析 (クラスタ・温度依存) を併用することで KT 転移近傍の挙動を潜在変数空間がどのように記述するか調べる。

3.5 本研究の教師なし・自己教師モデル (提案手法)

本研究では、教師なし学習に基づく潜在変数空間の解析を基盤としつつ KT 転移に特徴的な物理情報を潜在変数空間に反映させるため、Contrastive learning による対称学習と自己教師を組み合わせた学習手法を提案する。本節では、まず Contrastive learning による学習の枠組みを導入し、次に潜在変数と物理量を弱く結びつける自己教師信号の設計、最後に両者を統合した学習目的関数について述べる。

3.5.1 Contrastive learning による学習

Contrastive learning は、データ点間の類似性・非類似性を利用して学習する手法である。本研究では、SimCLR に基づく contrastive learning を採用し、同一スピン配置から生成された 2 つの拡張データを「正例ペア」、異なる配置に由来するデータを「負例ペア」として学習を行う。

入力

入力データは、二次元 XY モデルのスピン配置 $\{\phi_i\}$ から構成される。各格子点におけるスピン角 ϕ_i は周期変数であるため、入力は

$$x_i = (\cos \phi_i, \sin \phi_i) \quad (15)$$

の 2 チャンネルとし、全体としてサイズ $(2, L, L)$ のテンソルを用いる。

データ拡張の設計

Contrastive learning においては、拡張変換が XY モデルのハミルトニアンの特称性に基づき、エネルギーや渦数などの主要な物理的特徴を不変に保つ変換であることが重要である。本研究では以下のような変換を用いた。

- 全体回転： $\phi_i \rightarrow \phi_i + \alpha$ (α は一様乱数)
- 格子の並進および反転
- 微小なガウス雑音の付加（角度空間で周期性を保つように実装）

これらの変換はいずれも、渦構造やトポロジカル性を破壊しないことを意図して設計されている。

Encoder と潜在変数

入力データ x は畳み込みニューラルネットワークによる encoder f_θ によって潜在変数空間

$$\mathbf{h} = f_\theta(x) \quad (16)$$

へ写像される。さらに、projection head g_θ を通じて

$$\mathbf{z} = g_\theta(\mathbf{h}) \quad (17)$$

を得る。contrastive モデルにおける損失関数は $\mathbf{z}$ 空間上で定義され、encoder 出力 $\mathbf{h}$ は後述する物理解析に用いる。

NT-Xent 損失

2つの拡張データ (x_1, x_2) に対応する潜在変数 $(\mathbf{z}_1, \mathbf{z}_2)$ を用い、正規化温度付き交差エントロピー (NT-Xent) 損失を

$$\mathcal{L}_{\text{contr}} = -\frac{1}{2B} \sum_{i=1}^B \left[\log \frac{\exp(\text{sim}(\mathbf{z}_{1,i}, \mathbf{z}_{2,i})/\tau)}{\sum_{k \neq i} \exp(\text{sim}(\mathbf{z}_{1,i}, \mathbf{z}_k)/\tau)} + \log \frac{\exp(\text{sim}(\mathbf{z}_{2,i}, \mathbf{z}_{1,i})/\tau)}{\sum_{k \neq i} \exp(\text{sim}(\mathbf{z}_{2,i}, \mathbf{z}_k)/\tau)} \right] \quad (18)$$

と定義する。ここで sim はコサイン類似度、 τ は温度パラメータである。NT-Xent 損失は、正例ペア間の潜在変数の類似度を高める一方で、同一バッチ内の他のデータとの類似度を抑制するように学習を行う。この結果、データ拡張によって変化する全体回転や格子対称性などの対称性に起因する自由度に対して不変な拡張が促進され、一方でスピン配置間の構造的な違いに対応する拡張が潜在変数空間上で明確に分離されることが期待される。

3.5.2 Y 自己教師（潜在変数から物理量への回帰）

Contrastive learning のみでは、潜在変数空間はデータ分布の幾何構造を反映する一方で、どの物理量に対応するかは自明ではない。そこで本研究では、既知の物理量を「正解として当てに行く」のではなく、潜在変数空間に物理的方向性を弱く導入する目的で、自己教師信号 Y を併用する。

設計方針

本研究における自己教師信号の目的は、物理量 Y を高精度に予測することではない。むしろ、encoder 出力 $\mathbf{h}$ の潜在変数空間に、 Y に対応する自由度を一つの方向として弱く埋め込むことにある。

このような目的のもと、回帰タスクが潜在変数空間の構造を過度に規定することを避けるため、以下の設計を採用した。

- 回帰ヘッドは浅い MLP とする
- 非線形性は最小限に留める
- 損失の重みは contrastive loss に対して十分小さく設定する

回帰ヘッド

encoder 出力 $\mathbf{h} \in \mathbb{R}^D$ に対し、1 層の中間層を持つ回帰ヘッド

$$\hat{Y} = r_\psi(\mathbf{h}) \quad (19)$$

を定義する。本研究では、

$$\mathbb{R}^D \rightarrow \mathbb{R}^{D/4} \rightarrow \mathbb{R} \quad (20)$$

という小規模なネットワークを用い、過度な物理量への機械学習モデルの適合による潜在変数の歪みを防いでいる。

損失関数

自己教師信号に対する損失は、平均二乗誤差

$$\mathcal{L}_Y = \langle (\hat{Y} - Y)^2 \rangle \quad (21)$$

として定義する。ただし、この損失は単独で最小化されることはなく、contrastive loss と併用される。

3.5.3 Contrastive と Y 自己教師の統合

最終的な学習は、contrastive loss と Y 自己教師損失を組み合わせた以下の目的関数を最小化することで行う。

総損失関数

$$\mathcal{L} = \mathcal{L}_{\text{contr}} + \lambda_Y \mathcal{L}_Y \quad (22)$$

ここで λ_Y は自己教師信号の寄与を制御する重みであり、contrastive learning による学習を阻害しないよう、小さな値から段階的に増加させるスケジューリングを採用した。

以上の設計により、

- contrastive loss は潜在変数空間全体の幾何構造を規定し、相構造や温度依存性を自発的に学習する
- Y 自己教師は、潜在変数空間に物理量に対応する軸を弱く導入する

という役割分担が実現される。

本研究で用いる自己教師信号 Y として、ヘリシティ剛性 Υ を採用する。 Υ は、スピン配置に対する一様な位相ねじれに対する自由エネルギーの応答を表す量であり、 x 方向のヘリシティ剛性は式 (12) で定義される。ここで期待値 $\langle \cdot \rangle$ はモンテカルロ平均として評価した。

本研究では、 x および y 方向のヘリシティ剛性をそれぞれ算出し、それらを平均した量を系のヘリシティ剛性として定義した。この量を自己教師信号 Y とし、encoder 出力 $\mathbf{h}$ からの回帰対象として用いる。この選択により、局所的なスピン配置に基づく特徴学習に加えて、KT 転移に本質的な大域的剛性の情報を潜在変数空間に弱く反映させることを意図している。

3.6 潜在変数の解析

本研究では、学習済みモデルから得られる潜在変数の、KT 転移近傍における温度依存性および相構造を解析した。解析は主に、(i) 潜在変数の抽出、(ii) 温度ごとの統計量（平均・分散）による温度依存性の評価、(iii) 低次元可視化およびクラスタ解析による潜在変数空間の相構造の把握、(iv) 潜在変数と物理量（渦密度・ヘリシティ剛性等）の対応付けと可視化、の手順で行った。

3.6.1 潜在変数の抽出

学習済みの contrastive + 自己教師モデルに対し、モンテカルロシミュレーションから得られたスピン配置 x を入力し、各サンプルに対応する潜在変数を抽出した。

本研究では、contrastive loss が定義される空間と、物理解析に用いる潜在変数空間を区別するため、encoder の出力 $\mathbf{h}$ を潜在変数として採用する。一方、projection head を通した $\mathbf{z}$ は、学習時の contrastive loss の計算にのみ用い、後述する物理解析には使用しない。

3.6.2 潜在変数空間の構造の温度依存性 (latent vs T)

学習済みモデルから得られる潜在変数空間の構造が温度に対してどのように変化するかを定量的に評価するため、潜在変数を温度ごとに分類し、各温度における統計量（平均および標準偏差）を算出した。

具体的には、モンテカルロシミュレーションにより得られた各スピン配置に対し、encoder 出力として得られる潜在変数 $\mathbf{h}_n = (h_{n,1}, \dots, h_{n,D})$ と対応する温度 T_n を保存する。温度 T に属するサンプル集合を $\mathcal{D}_T = \{n \mid T_n = T\}$ と定義すると、潜在次元 d における温度条件付き平均は

$$\langle h_{n,d} \rangle_T = \frac{1}{|\mathcal{D}_T|} \sum_{n \in \mathcal{D}_T} h_{n,d} \quad (23)$$

として評価される。同様に、温度 T における標準偏差を

$$\sigma_{h_d}(T) = \sqrt{\frac{1}{|\mathcal{D}_T|} \sum_{n \in \mathcal{D}_T} (h_{n,d} - \langle h_{n,d} \rangle_T)^2} \quad (24)$$

と定義した。

本研究では、全潜在次元に対してこれらの統計量を評価した上で、温度依存性が顕著に現れる潜在次元を抽出し、それらについて $\langle h_{n,d} \rangle_T$ の温度依存性を可視化した。この解析により、KT 転移近傍で急激な立ち上がりや減衰を示す方向が共存していることが分かった。これは、温度の変化に対する系の応答が、潜在変数空間上で複数の独立なモードに分解されて、KT 転移に内在する渦対の解離に伴う渦密度の増加や、ヘリシティ剛性のジャンプといった物理的特徴を反映していると考えられる。

3.6.3 クラスタ解析による相構造の抽出

潜在変数空間における相構造を把握するため、低次元可視化およびクラスタ解析を併用した。まず、潜在変数空間の幾何構造（連続的変形や密度変化）を視覚的に把握するため、t-SNE により潜在変数 $\mathbf{h} \in \mathbb{R}^D$ を 2 次元空間へ埋め込み、可視化を行った。t-SNE は局所近傍構造の保存を目的としており、高次元潜在変数空間における分布の変化を比較するのに有効である。

次に、潜在変数空間上の相構造を定量的に評価するため、潜在変数 $\mathbf{h}$ に対して K-means 法によるクラスタリングを適用し、各サンプルにクラスタラベル $c_n \in \{0, 1, \dots, K-1\}$ を付与した。ここでクラスタ数 K は、KT 相と高温相の分離を過度に仮定しない範囲で設定した。

温度 T におけるクラスタ出現確率を

$$P_T(c = k) = \frac{1}{|\mathcal{D}_T|} \sum_{n \in \mathcal{D}_T} \mathbf{1}[c_n = k] \quad (25)$$

として定義し、これを温度に対してプロットすることで、潜在変数空間上で各クラスタがどの温度領域で支配的となるか、あるいは複数のクラスタが混合するかを評価した。この解析により、潜在変数空間におけるクラスタ構造が、温度変化に伴う相構造の変化を反映しているかを定量的に確認した。

3.6.4 潜在変数空間と物理量の対応付け

潜在変数空間において分離されたクラスタが、物理的に異なる統計状態を反映しているかを検証するため、物理量との対応付けを行った。本研究では特に、渦密度 n_v およびヘリシティ剛性 Υ に注目し、潜在変数空間上のクラスタと物理量との対応を調べた。これらの物理量は、KT 転移においてそれぞれ渦対の解離および剛性の消失を特徴づける量である。

クラスタ付与済みサンプルに対して、温度 T およびクラスタ k を固定した条件付き平均

$$\langle O \rangle_{T,k} = \frac{1}{|\mathcal{D}_{T,k}|} \sum_{n \in \mathcal{D}_{T,k}} O_n, \quad \mathcal{D}_{T,k} = \{n \mid T_n = T, c_n = k\} \quad (26)$$

を評価し、 $O \in \{n_v, \Upsilon\}$ の温度依存性をクラスタごとに比較した。このとき、潜在変数空間上で分離されたクラスタが、物理量においても異なる統計的性質を示すかどうかを検証した。

さらに、潜在変数空間におけるクラスタ分離が空間相関の性質と対応しているかを調べるため、クラスタ条件付きの相関関数解析を行った。各スピン配置から計算した相関関数 $G(r)$ を、同一の温度およびクラスタに属するサンプルについて平均することで、

$$G_{T,k}(r) = \frac{1}{|\mathcal{D}_{T,k}|} \sum_{n \in \mathcal{D}_{T,k}} G_n(r) \quad (27)$$

を定義した。これにより、潜在変数空間上で分離されたクラスタが、準長距離秩序を示す相関（べき的減衰）と、短距離秩序を示す相関（指数的減衰）に対応しているかを評価した。

以上の解析を通じて、潜在変数空間におけるクラスタ構造が、単なる数値的分割ではなく、KT 転移に特徴的な物理的状态の違いを反映した結果であるかどうかを検証した。

4 結果

4.1 教師あり学習

本節では、教師あり学習によって構築した分類モデルの結果を示し、二次元 XY モデルにおける相構造および Kosterlitz–Thouless (KT) 転移近傍の特徴が、どの程度までスピン配置から学習可能であることを検証する。特に、分類性能、出力不確実性、および潜在変数空間の構造に着目し、教師あり学習が捉える情報の性質とその限界を明らかにする。

本節で用いる教師ありモデルは前章で述べたとおり、相を厳密に判定する分類器としてではなく後述する教師なし学習によって得られる潜在変数空間の構造と比較するための参照的な基準として位置づけられている。

4.1.1 教師あり学習の分類性能

まず、教師あり分類モデルの基本的な性能を評価するため温度ごとの分類精度 (Accuracy) を算出した。Accuracy の温度依存性を 図. 4.1.1 に示す。




図 4.1.1: 教師あり分類モデルにおける分類精度 (Accuracy) の温度依存性。KT 相および高温相では高い分類精度が維持される一方、相ラベルの境界付近に対応する温度領域では分類精度の低下が観測される。

KT 相および高温相では、安定して高い分類精度が得られており、スピン配置に含まれる統計的特徴が十分に識別可能であることが分かる。

一方で、KT 転移近傍に位置する温度領域においても多くの温度点では依然として高い Accuracy が維持されているが、温度領域に基づいて定義した相ラベルの境界付近では分類精度が顕著に低下する温度点が存在することが確認された。

この挙動は分類性能の低下が単に「KT 転移近傍であること」に起因するのではなく、有限サイズ系において連続的に変化する相構造を離散的な相ラベルによって区切っていることに強く依存していることを示唆している。すなわち、モデルが内部で学習している潜在変数空間は連続的である一方、教師ラベルの定義が境界的であるためその不整合が分類性能の低下として現れていると解釈できる。

4.1.2 出力不確実性の温度依存性

次に、分類結果に付随する不確実性を定量化するためモデル出力の softmax 確率分布に基づくエントロピーを計算した。softmax エントロピーの温度依存性を 図. 4.1.2 に示す。




図 4.1.2: 教師あり分類モデルの softmax 出力分布から計算したエントロピーの温度依存性。KT 相および高温相ではエントロピーは小さい値を示す一方、相ラベルの境界付近に対応する温度領域ではエントロピーの顕著な増大が観測される。

KT 相および高温相では、エントロピーは小さな値を示しており、モデルが特定の相ラベルに対して高い確信度を持って予測していることが分かる。一方、温度が上昇して KT 転移近傍に近づくにつれて、エントロピーは増大し、特に相ラベルの境界付近で明確なピークを示す。

このエントロピーのピークは、図. 4.1.1 に示した分類精度の低下とよく対応しており、モデルが「どの相に属するか」を一意に判断できなくなっていることを反映している。すなわち、softmax エントロピーは、教師あり学習モデルにおいて KT 転移近傍における相構造の曖昧さや揺らぎを感度良く捉える指標として機能している。

ただし、ここで観測されるエントロピーのピークは、KT 転移温度そのものを厳密に同定しているわけではない点に注意が必要である。前節で述べたように有限サイズ系において連続的に変化する相構造に対し、温度領域に基づいて境界的な相ラベルを付与している。そのため、エントロピーの増大は、転移そのものの非連続性を直接反映しているというよりも、連続的に変化するスピン配置と、離散的に定義された教師ラベルとの間に生じる不整合が、分類の不確実性として顕在化した結果と解釈するのが適切である。

したがって、softmax エントロピーは転移温度の精密な決定指標というよりも、有限サイズ系における KT 転移近傍の構造的曖昧さを捉える量として理解されるべきである。

4.1.3 潜在変数空間の可視化

教師あり学習によって得られた潜在変数空間の幾何構造を調べるため、t-SNE により 2 次元空間へ埋め込み、可視化を行った。その結果を図. 4.1.3 に示す。




図 4.1.3: 教師あり分類モデルによって得られた潜在変数を t-SNE により 2 次元空間へ埋め込み、可視化した結果。各点は一つのスピン配置に対応し、色は教師ラベルとして与えた温度領域（相）を表す。KT 相および高温相に対応するサンプルは、それぞれ潜在変数空間上で高い密度を持つ領域として分離して分布している一方、相ラベルの境界付近に対応するサンプルは、異なる相領域の間に連続的に配置されている。

KT 相および高温相に対応するサンプルは、潜在変数空間上においてそれぞれ高い密度を持つ領域として分布しており、異なる温度領域同士の重なりは限定的である。すなわち、同一温度領域に属するサンプル同士は潜在変数空間上で近接して配置される傾向を示している。

一方で、これらの領域は明確に分離されたクラスタとして切り分けられているわけではなく、温度の変化に伴って連続的に位置を変える構造を持つ。特に、KT 転移近傍に対応するサンプルは、KT 相と高温相の間を連続的に補間するように分布しており離散的な境界を持たない中間的な構造を形成している。

この結果は、教師ありモデルの潜在変数空間が相構造を離散的なクラスとしてではなく、温度に伴って連続的に変形する構造として表現していることを示唆している。特に KT 転移は局所的な秩序変数の非連続的な変化を伴わない転移であるため、潜在変数空間上で中間的な領域として表現されることは自然な結果であると解釈できる。

以上の結果から、教師あり学習は相構造の大局的な違いを捉える能力を持つ一方で KT 転移に内在する連続性や曖昧さを機械学習内部の構造として保持していることが分かる。この性質は、次節で述べる教師なし学習による潜在変数空間解析の意義を明確に裏付けるものである。

4.2 教師なし学習（contrastive + 自己教師）による相構造解析

本節では、contrastive learning と自己教師信号を統合した教師なし学習モデルを用いて、二次元 XY モデルにおける相構造および Kosterlitz–Thouless (KT) 転移近傍の特徴を解析する。前節で述べた教師あり学習とは異なり、本節では相ラベルを一切与えずに学習を行い、スピン配置から獲得された潜在変数空間の構造そのものが、温度変化や物理量とどのように対応しているかに着目する。

特に、(i) 潜在変数空間における相構造の自発的形成、(ii) 潜在変数の温度依存性、(iii) 潜在変数と物理量との対応関係の三点を順に検証することで、教師なし学習によって得られる潜在変数空間が KT 転移に特徴的な構造をどの程度反映しているかを明らかにする。

4.2.1 潜在変数空間における相構造の自発的形成

教師なし学習によって獲得された潜在変数空間が、温度変化に伴う相構造をどの程度反映しているかを調べるため、潜在変数に対してクラスタ解析および低次元可視化を行った。ここでは、前節で触れた教師あり学習の場合とは異なり相ラベルや物理量に基づく明示的な情報を一切用いずに、潜在変数空間上に自発的に形成される構造に着目する。

まず、学習済みモデルから抽出した潜在変数に対してクラスタリングを適用し、各温度におけるクラスタ出現確率の温度依存性を評価した。その結果を図. 4.2.1 に示す。




図 4.2.1: 潜在変数に対するクラスタリング結果から得られた、各温度 T におけるクラスタ出現確率 $P_T(\text{cluster} = k)$ の温度依存性。低温領域および高温領域ではそれぞれ特定のクラスタが支配的となる一方、KT 転移近傍では複数のクラスタが共存しており、潜在変数空間の構造が温度に対して連続的に遷移していることが分かる。

その結果、低温領域および高温領域ではそれぞれ特定のクラスタが支配的となる傾向が確認された。一方で、KT 転移近傍に対応する温度領域では複数のクラスタが共存する温度帯が広く存在し、単一のクラスタによって特徴付けられないことが分かった。

このようなクラスタ出現確率の温度依存性は、潜在変数空間の構造が温度の変化に伴って離散的に切り替わるのではなく、連続的に遷移していることを示唆している。前節で述べた教師あり学習においても相構造が明確な境界を持たず連続的に変化する様子が内部構造として現れていたが、本結果は教師ラベルを用いない場合においても同様の連続性が潜在変数空間の構造として自発的に形成されることを示している。

さらに、潜在変数を t-SNE により低次元へ埋め込み潜在変数空間の幾何構造を可視化した。温度による連続着色を施した t-SNE 可視化を図. 4.2.2 に示す。




図 4.2.2: 潜在変数を t-SNE により 2 次元へ埋め込んだ結果。各点は温度 T により連続的に着色されている。温度の上昇に伴って分布が連続的に変形しており、潜在変数空間上に明確な不連続や離散的な境界が存在しないことが確認される。

その結果、低温領域および高温領域に対応するサンプルはそれぞれ比較的高い密度を持つ領域として分布する一方、KT 転移近傍に対応するサンプルはそれらの領域の間を連続的に補間するように配置されていることが確認された。この分布は、潜在変数空間上において KT 転移近傍が中間的な構造として機械学習内部に保持されていることを示唆している。温度領域ごとの分布を図. 4.2.3 に示す。なお、温度領域の境界については教師有り学習と同じものを採用している。




図 4.2.3: 潜在変数の t-SNE 可視化を、温度領域ごと（低温、相転移近傍、高温）に色分けした結果。KT 相および高温相に対応するサンプルはそれぞれ異なる領域に分布する一方、KT 転移近傍に対応するサンプルは両者の間を連続的に埋めるように分布している。

以上の結果から、contrastive learning と自己教師信号を統合した教師なし学習モデルは、相ラベルを与えずとも潜在変数空間の構造として KT 相、高温相、およびその中間に位置する KT 転移近傍の特徴を自発的に捉えていることが分かる。この性質は、局所的な秩序変数を持たない KT 転移に対して潜在変数空間そのものを解析対象とするアプローチが有効であることを示している。

4.2.2 潜在変数空間構造の温度依存性と物理量との対応

次に、潜在変数空間の構造が温度に対してどのように変化するかを調べるため、潜在変数の統計量の温度依存性を評価した。学習済みモデルから抽出した各サンプルの潜在変数 $h_n = (h_{n,1}, \dots, h_{n,D})$ を温度ごとに分類し、各潜在次元に対する温度条件付き平均 $\langle h_d \rangle_T$ を算出した。

その結果、温度上昇に伴って単調に変化する潜在方向、KT 転移近傍において急激な立ち上がりや減衰を示す潜在方向、および温度に対して明確な系統性を持たない潜在方向が共存していることが確認された。このことは、潜在変数空間の構造が単一の秩序変数に還元されるのではなく、KT 転移に特徴的な複数の物理過程を多成分的に含んでいることを示している。

しかし、高次元の潜在変数空間には、物理的意味を持たない自由度や統計的揺らぎに起因する成分も含まれていると考えられる。そこで、潜在変数と既知の物理量との対応関係を定量的に評価し、物理量と強く関連する潜在成分を抽出することを試みた。

本研究では、KT 転移において本質的な役割を果たす渦密度 n_v およびヘリシティ剛性 Υ に注目した。KT 転移近傍では、これらの物理量の温度依存性が強い非線形性を示し、有限サイズ効果により単調性が緩やかに破れる場合がある。そのため、線形相関係数である Pearson 相関ではなく、単調関係の検出に適した Spearman の順位相関係数を用いた。

各潜在次元 d に対して、

$$\rho_d^{(Y)} = \text{Corr}_{\text{Spearman}}(h_{n,d}, Y_n), \quad Y \in \{n_v, \Upsilon\}$$

を計算し、物理量と単調な関係を持つ潜在成分を評価した。その結果、多くの潜在成分では相関係数は小さく、物理量との明確な対応は確認されなかった。一方で、一部の潜在成分においては、

渦密度と強い正の相関を示す成分、およびヘリシティ剛性と強い負の相関を示す成分が存在することが分かった。

まず、渦密度 n_v の温度依存性を図. 4.2.4 に示す。




図 4.2.4: モンテカルロシミュレーションから計算した渦密度 n_v の温度依存性。低温領域では渦密度はほとんどゼロに抑えられているが、温度上昇に伴い KT 転移近傍から急激に増加し、高温領域では有限の値を取る。

低温領域では渦密度はほぼゼロに抑えられているが、KT 転移近傍から急激に増加し、高温領域では有限の値を取る。これに対応して、渦密度と強い相関を示した潜在成分の温度条件付き平均 $\langle h_d \rangle_T$ を図. 4.2.5 に示す。




図 4.2.5: 渦密度 n_v と強い相関を示した潜在変数成分の可視化。 $\rho_d^{(n_v)} = 0.782$ であった。低温領域では小さな値を保つ一方、KT 転移近傍から顕著な立ち上がりを示しており、渦対の解離に伴う渦密度の増殖過程を潜在変数空間の構造として捉えていることが示唆される。

この潜在成分は、渦密度の増加と同様に、KT 転移近傍で顕著な立ち上がりを示しており、渦対

の解離に伴うトポロジカル欠陥の増殖過程を潜在変数空間の構造として捉えていることが分かる。
次に、ヘリシティ剛性 $\Upsilon(T)$ の温度依存性を図. 4.2.6 に示す。




図 4.2.6: モンテカルロシミュレーションから計算したヘリシティ剛性 $\Upsilon(T)$ の温度依存性。低温領域では有限な剛性が保たれているが、KT 転移近傍において急激に減衰し、高温領域ではゼロに近づく。この挙動は、ヘリシティ剛性の消失という KT 転移に固有の性質を反映している。

低温領域では有限値を保つ一方、KT 転移近傍において急激に減衰し高温領域ではゼロに近づく挙動が確認される。この温度依存性と強い相関を示した潜在変数成分の温度条件付き平均を図. 4.2.7 に示す。




図 4.2.7: ヘリシティ剛性 Υ と強い相関を示した潜在成分についての可視化。 $\rho_d^{(\Upsilon)} = 0.658$ であった。潜在変数成分は、温度上昇に伴って全体として単調に減少する挙動を示し、KT 転移近傍に対応する温度範囲では、減衰の傾きの変化および変動の増大が観測される。

低温領域では比較的大きな値を保ち、温度上昇に伴って全体として単調に減少する挙動が確認

される。特に、KT 転移近傍に対応する温度範囲 $T \simeq 0.9\text{--}1.1$ では、減衰の傾きが変化するとともに、値の変動がやや大きくなる傾向が見られる。

この挙動は、有限サイズ系においてヘリシティ剛性が不連続なジャンプとしては現れず、転移近傍で滑らかに減衰するという性質と整合的である。すなわち、ヘリシティ剛性の消失に対応する大域的物理過程が、潜在変数空間の特定の方向において緩やかな変化として反映されていると考えられる。

以上の結果から、contrastive learning と自己教師信号を統合した本手法によって得られた潜在変数空間の構造には、渦の解離に対応する方向と、ヘリシティ剛性の消失に対応する方向が、異なる潜在方向として同時に存在していることが明らかとなった。すなわち、局所的な秩序変数を持たない KT 転移においても、潜在変数空間の温度依存性を解析することで、転移に本質的な複数の物理過程を分離して捉えることが可能である。

このことは、潜在変数空間そのものを解析対象とし、その温度依存性と物理量との対応関係を調べるアプローチが、KT 転移の相構造理解において有効であることを示している。

4.3 クラスタ条件付き相関関数による空間構造の解析

本節では、潜在変数空間上で得られたクラスタに基づいてサンプルを分類しそれぞれのクラスタに対するスピン相関関数 $G(r)$ の振る舞いを解析する。ここで得られるクラスタは相を分類するものではなく、同一温度条件下におけるスピン配置の空間的特徴の違いを潜在変数空間の構造に基づいて切り分けたものである。

相関関数は

$$G(r) = \langle \cos(\theta_i - \theta_j) \rangle_{|i-j|=r}$$

として定義し、距離 r に対する平均を取ることで評価した。KT 転移においては長距離秩序が存在しない一方で、低温領域では準長距離秩序が現れることが知られており相関関数は空間構造を捉える基本的な物理量である。

図. 4.3.1 に潜在変数空間上で得られたクラスタごとに分類したサンプルについて、複数の温度条件における相関関数 $G(r)$ を示す。




図 4.3.1: 潜在変数空間上で得られたクラスタごとに分類したサンプルについて、スピン相関関数 $G(r) = \langle \cos(\theta_i - \theta_j) \rangle$ を距離 r の関数として示す。図は、低温領域 $T = 0.80$, KT 転移近傍 $T = 1.00$, 高温領域 $T = 1.20$ に対応する温度条件における結果をそれぞれ log-log 表示および semi-log 表示で示している。各温度条件において相関関数の減衰の仕方にはクラスタ間で差が見られ、潜在変数空間に基づくクラスタリングがスピン配置の空間相関という観点からも、異なる特徴を持つ構成を切り分けていることが分かる。

低温領域に対応する温度では、すべてのクラスタにおいてべき的な減衰が観測されるが観測されたクラスタごとに減衰の仕方に差が存在していることが分かる。

KT 転移近傍に対応する温度条件では、相関関数の減衰の傾きや距離依存性においてクラスタ間の違いがより明瞭になる。

一方、高温領域に対応する温度では高温に対応するクラスタにおいて相関が指数的に減衰する傾向が見られた一方で、中間領域に対応するクラスタの減衰の程度や形状に差異が観測された。

これらの結果は、潜在変数空間に基づくクラスタリングがスピン配置の空間相関という観点から見ても、物理的に異なる特徴を持つ構成を切り分けていることを示している。すなわち、潜在変数空間の構造は局所的なスピン配置の違いにとどまらず、相関関数によって特徴づけられる空間構造の違いをも反映していることが示唆される。

以上より、潜在変数空間を用いたクラスタリングはKT 転移における空間相関の多様な振る舞いを整理する上で有効であり、相関関数という基本的な物理量を通じてその物理的妥当性が支持される。

5 まとめ

5.1 考察

本研究では、二次元 XY モデルにおける Kosterlitz–Thouless (KT) 転移を対象として、自己教師信号と contrastive learning を統合した深層学習モデルを用い、スピン配置データの潜在変数空間を解析した。

第4章では、潜在変数空間の温度依存性と物理量との対応関係を調べることで、高次元な潜在変数空間の中から、KT 転移に本質的な物理過程と関連する方向を抽出できることを示した。特に、潜在変数の温度条件付き平均や相関解析を通じて、温度上昇に伴う系の変化が、潜在変数空間の特定の方向に反映されていることが確認された。

また、潜在変数空間に基づいて得られたクラスタを用いて、スピン相関関数 $G(r)$ の振る舞いを解析した結果、同一温度条件下においても、空間相関の減衰特性が異なる構成が存在することが明らかとなった。これは、潜在変数空間が、局所的なスピン配置の違いにとどまらず、相関関数によって特徴づけられる空間構造の差異をも反映していることを示唆している。

これらの結果は、明確な局所秩序変数を持たない KT 転移に対して、潜在変数空間を解析対象とするアプローチが有効であることを示している。すなわち、深層学習によって構成された潜在変数空間は、物理量や空間相関といった異なる観点からの情報を統合的に保持しており、相転移に伴う構造変化を多面的に捉える表現として機能していると考えられる。

5.2 結論と今後の展望

本研究では、深層学習モデルによって得られた潜在変数空間を用い、KT 転移に特徴的な物理過程を定量的に解析する手法を提案した。潜在変数空間の解析を通じて、渦の解離や位相剛性の低下に対応する物理的变化が、高次元表現の中に分離された形で埋め込まれていることが示された。さらに、潜在変数空間に基づくクラスタリングを用いることで、スピン相関関数という基本的な物理量の振る舞いを整理できることが確認された。

以上より、本研究で用いた潜在変数空間解析の枠組みは、従来の秩序変数に基づく解析が困難な相転移に対しても、有効な解析手法となる可能性を持つ。特に、物理量との相関解析や空間相関関数との対応付けを組み合わせることで、機械学習による表現を物理的に解釈可能な形で利用できる点に本研究の意義がある。

今後の展望としては、系サイズを拡張した有限サイズスケーリング解析への適用や、他のトポロジカル相転移を示すモデルへの応用が挙げられる。また、教師信号の設計や潜在変数空間の構造制御を工夫することで、より物理的解釈性の高い表現を得ることも今後の課題である。これらの方向に発展させることで、深層学習を用いた相転移解析の枠組みを、より一般的な物理系へと拡張できると期待される。

参考文献

- [1] J. M. Kosterlitz and D. J. Thouless. Ordering, metastability and phase transitions in two-dimensional systems. *Journal of Physics C: Solid State Physics*, 6:1181–, 1973.
- [2] N. D. Mermin and H. Wagner. Absence of ferromagnetism or antiferromagnetism in one- or two-dimensional isotropic heisenberg models. *Physical Review Letters*, 17:1133–, 1966.
- [3] N. Metropolis, A. W. Rosenbluth, M. N. Rosenbluth, A. H. Teller, and E. Teller. Equation of state calculations by fast computing machines. *The Journal of Chemical Physics*, 21:1087–1092, 1953.
- [4] Michael Creutz. Molecular dynamics monte carlo. *Physical Review D*, 36:515–519, 1987.
- [5] Stephen L. Adler. Over-relaxation method for the monte carlo evaluation of the partition function for multiquadratic actions. *Physical Review D*, 23:2901–2904, 1981.
- [6] Gareth O. Roberts, Andrew Gelman, and Walter R. Gilks. Weak convergence and optimal scaling of random walk metropolis algorithms. *The Annals of Applied Probability*, 7(1):110–120, 1997.
- [7] Sebastian J. Wetzl. Unsupervised learning of phase transitions: from principal component analysis to variational autoencoders. *arXiv preprint arXiv:1703.02435*, 2017.

- [8] Lei Wang. Discovering phase transitions with unsupervised learning. *arXiv preprint arXiv:1606.00318*, 2016.
- [9] Ting Chen, Simon Kornblith, Mohammad Norouzi, and Geoffrey Hinton. A simple framework for contrastive learning of visual representations. In *Proceedings of the 37th International Conference on Machine Learning*, volume 119 of *Proceedings of Machine Learning Research*, pages 1597–1607. PMLR, 2020.
- [10] Evert P. L. van Nieuwenburg, Ye-Hua Liu, and Sebastian D. Huber. Learning phase transitions by confusion. *Nature Physics*, 13(5):435–439, 2017.
- [11] Chi-Ting Ho and Daw-Wei Wang. Robust identification of topological phase transition by self-supervised machine learning approach. *New Journal of Physics*, 23, August, 2021.